

E-commerce Business Intelligence Dashboard

Analyse des ventes e-commerce avec le dataset Olist

Rapport d'analyse Business Intelligence

Auteur : Aissaoui Mohammed Reda

Email : aissaouimohammedreda@gmail.com

LinkedIn : linkedin.com/in/aissaouimohammedreda

Projet : Dashboard BI — Analyse des ventes e-commerce

Dataset : Brazilian E-Commerce Public Dataset by Olist

Outils utilisés : Python, Pandas, SQL, SQLite, Power BI, DAX

May 5, 2026

Contents

Version française	3
1 Contexte du projet	3
2 Objectifs business	3
3 Présentation du dataset	4
4 Méthodologie	5
4.1 Compréhension et exploration des données	5
4.2 Nettoyage et préparation avec Python	5
4.3 Analyse SQL	5
4.4 Dashboard Power BI	6
5 KPIs principaux	6
6 Analyse des ventes	7
7 Analyse client	7
8 Analyse livraison	7
9 Recommandations business	8
9.1 Améliorer la fidélisation client	8
9.2 Renforcer les catégories performantes	8
9.3 Exploiter les régions à fort potentiel	8
9.4 Réduire les retards de livraison	9
9.5 Identifier les produits premium	9
10 Conclusion	9
English Version	10
11 Project Context	10
12 Business Objectives	10
13 Dataset Overview	11
14 Methodology	12
14.1 Data Understanding and Exploration	12
14.2 Data Cleaning and Preparation with Python	12
14.3 SQL Analysis	12

14.4 Power BI Dashboard	13
15 Main KPIs	13
16 Sales Analysis	14
17 Customer Analysis	14
18 Delivery Analysis	14
19 Business Recommendations	15
19.1 Improve Customer Retention	15
19.2 Strengthen High-Performing Categories	15
19.3 Leverage High-Potential Regions	15
19.4 Reduce Delivery Delays	15
19.5 Identify Premium Products	16
20 Conclusion	16

Version française

1. Contexte du projet

Ce projet a été réalisé dans le but de construire une analyse Business Intelligence complète à partir de données e-commerce réelles. L'idée principale est de se placer dans une situation proche d'un cas professionnel, où une entreprise souhaite mieux comprendre ses performances commerciales, ses clients, ses produits et ses problématiques de livraison.

Dans un environnement e-commerce, les décisions ne peuvent pas se baser uniquement sur le chiffre d'affaires global. Il est nécessaire d'analyser plusieurs dimensions : l'évolution des ventes dans le temps, la performance des catégories de produits, la répartition géographique des ventes, la fidélité client, ainsi que la qualité de la livraison.

Ce projet suit une démarche complète de Data Analyst / BI Analyst. Les données brutes ont d'abord été explorées, nettoyées et transformées avec Python. Ensuite, des requêtes SQL ont été rédigées pour calculer les principaux indicateurs business. Enfin, un dashboard Power BI a été construit afin de rendre les résultats lisibles, interactifs et exploitables.

L'objectif n'est donc pas seulement de produire des graphiques, mais de transformer un ensemble de fichiers bruts en un véritable outil d'aide à la décision.

2. Objectifs business

L'analyse vise à répondre à plusieurs questions importantes pour une entreprise e-commerce :

- Quel est le chiffre d'affaires généré par les commandes livrées ?
- Combien de commandes ont été finalisées ?
- Quel est le panier moyen ?
- Quelles catégories de produits génèrent le plus de chiffre d'affaires ?
- Quelles régions sont les plus performantes ?
- Quels produits contribuent le plus au chiffre d'affaires ?
- Quel est le niveau de fidélité des clients ?
- Quel est le taux de réachat ?
- Quels clients commandent le plus souvent ?
- Quels clients génèrent le plus de revenus ?
- Quel est le délai moyen de livraison ?

- Quelles régions présentent les taux de retard les plus élevés ?

Ces questions permettent de couvrir trois axes essentiels : la performance commerciale, le comportement client et la performance logistique.

3. Présentation du dataset

Le dataset utilisé est le **Brazilian E-Commerce Public Dataset by Olist**. Il s'agit d'un dataset public contenant des données anonymisées issues d'une marketplace brésilienne.

Les données couvrent plusieurs aspects du processus e-commerce :

- les commandes ;
- les clients ;
- les produits ;
- les catégories de produits ;
- les paiements ;
- les vendeurs ;
- les avis clients ;
- les dates de livraison ;
- les informations géographiques.

Le dataset est composé de plusieurs fichiers CSV reliés entre eux par des identifiants comme `order_id`, `customer_id`, `product_id` ou encore `seller_id`.

Pour construire l'analyse principale, les tables les plus importantes ont été :

- `olist_orders_dataset.csv` ;
- `olist_order_items_dataset.csv` ;
- `olist_customers_dataset.csv` ;
- `olist_products_dataset.csv` ;
- `olist_order_payments_dataset.csv` ;
- `product_category_name_translation.csv`.

L'analyse finale se concentre principalement sur les commandes ayant le statut **delivered**. Ce choix permet de mesurer les ventes réellement finalisées et d'éviter d'intégrer dans les KPIs des commandes annulées, indisponibles ou encore en cours de traitement.

4. Méthodologie

La méthodologie suivie dans ce projet est structurée en quatre grandes étapes.

4.1. Compréhension et exploration des données

La première étape a consisté à charger les fichiers CSV dans un notebook Python afin d'observer leur structure, le nombre de lignes, les colonnes disponibles, les types de données, les valeurs manquantes et les doublons.

Cette phase est essentielle, car elle permet d'éviter de construire des KPIs sur des données mal comprises. Par exemple, une commande peut contenir plusieurs produits, ce qui signifie que la table des lignes de commande possède plus de lignes que la table des commandes.

4.2. Nettoyage et préparation avec Python

Les colonnes de dates ont été converties au format datetime afin de permettre les analyses temporelles. Les catégories produits manquantes ont été remplacées par la valeur **unknown**, afin de conserver les ventes associées à ces produits sans perdre de chiffre d'affaires.

Une table centrale appelée **sales_clean** a été construite en combinant les commandes, les lignes de commande, les clients, les produits, les catégories et les paiements.

Une seconde table appelée **sales_delivered** a ensuite été créée pour ne conserver que les commandes livrées. Cette table a servi de base principale pour les analyses SQL et le dashboard Power BI.

4.3. Analyse SQL

Une base SQLite a été créée afin d'importer les données propres. Plusieurs requêtes SQL ont été rédigées pour calculer les KPIs et réaliser les analyses principales :

- chiffre d'affaires total ;
- nombre de commandes ;
- nombre de clients uniques ;
- panier moyen ;
- évolution mensuelle des ventes ;
- ventes par catégorie ;
- ventes par région ;
- top produits ;

- clients les plus fidèles ;
- taux de réachat ;
- délais de livraison ;
- taux de retard par région.

Cette étape a permis de valider les résultats avant de les visualiser dans Power BI.

4.4. Dashboard Power BI

Le dashboard Power BI a été construit autour de plusieurs pages :

- **Executive Overview** : vue globale des KPIs principaux ;
- **Sales Analysis** : analyse des ventes par mois, catégorie, région et produit ;
- **Delivery Analysis** : analyse des délais et des retards de livraison ;
- **Customer Loyalty** : analyse de la fidélité client et des clients à forte valeur.

Des mesures DAX ont été créées afin de calculer dynamiquement les indicateurs dans le dashboard.

5. KPIs principaux

Les principaux indicateurs calculés à partir des commandes livrées sont les suivants :

KPI	Valeur
Chiffre d'affaires total	13 221 498.11
Commandes livrées	96 478
Clients uniques	93 358
Articles vendus	110 197
Panier moyen	137.04
Taux de réachat	3.00 %
Délai moyen de livraison	12.01 jours
Taux de retard de livraison	7.91 %

Ces KPIs donnent une vision synthétique de la performance globale de l'activité e-commerce.

6. Analyse des ventes

L'analyse des ventes montre que le chiffre d'affaires total des commandes livrées atteint environ **13.22 millions**. Ce chiffre représente les revenus générés par les produits vendus, hors frais de livraison.

L'analyse mensuelle permet d'observer l'évolution du chiffre d'affaires au fil du temps. Elle permet d'identifier les périodes de croissance, les mois plus faibles et les tendances saisonnières potentielles.

L'analyse par catégorie met en évidence les catégories les plus performantes. La catégorie **health_beauty** arrive en tête en termes de chiffre d'affaires. Elle est suivie par des catégories comme **watches_gifts**, **bed_bath_table**, **sports_leisure** et **computers_accessories**.

Un point intéressant est que certaines catégories peuvent générer un chiffre d'affaires élevé avec un volume de commandes plus faible, grâce à un panier moyen plus important. C'est notamment le cas de certaines catégories premium.

L'analyse par région montre que l'État de **SP** est largement dominant en volume de ventes et en chiffre d'affaires. Les régions **RJ** et **MG** suivent également parmi les zones les plus importantes.

7. Analyse client

L'analyse client montre que le dataset contient **93 358 clients uniques** pour **96 478 commandes livrées**. Le nombre de clients est donc très proche du nombre de commandes, ce qui indique que la majorité des clients n'ont effectué qu'un seul achat.

Le taux de réachat calculé est de seulement **3.00 %**. Ce résultat montre que la fidélisation client est un axe d'amélioration important. Une entreprise e-commerce avec un taux de réachat faible peut être fortement dépendante de l'acquisition de nouveaux clients, ce qui peut augmenter les coûts marketing.

L'analyse des meilleurs clients par nombre de commandes permet d'identifier les clients les plus fidèles. L'analyse des meilleurs clients par chiffre d'affaires permet quant à elle d'identifier les clients à forte valeur. Ces deux dimensions ne sont pas toujours identiques : un client peut commander souvent mais dépenser peu, tandis qu'un autre peut commander moins souvent mais générer un montant total plus élevé.

Cette distinction est importante pour construire des actions marketing adaptées.

8. Analyse livraison

La performance de livraison est un élément important dans l'expérience client. Dans ce projet, le délai moyen de livraison est d'environ **12.01 jours**.

Le taux de retard de livraison est de **7.91 %**. Cela signifie qu'environ 8 articles sur 100 ont été livrés après la date estimée.

L'analyse par région montre que certaines zones présentent des taux de retard plus élevés que la moyenne, notamment **AL**, **MA**, **SE**, **PI** et **CE**. Ces régions mériteraient une analyse logistique plus approfondie afin d'identifier les causes possibles : distance, réseau de transport, vendeurs, préparation des commandes ou partenaires de livraison.

Il est également important de distinguer le taux de retard et le délai moyen. Une région peut avoir un délai moyen élevé sans forcément avoir un taux de retard très important si les dates estimées sont elles-mêmes longues. À l'inverse, une région peut avoir un délai moyen raisonnable mais un taux de retard élevé si les délais promis sont trop courts.

9. Recommandations business

À partir des résultats obtenus, plusieurs recommandations peuvent être proposées.

9.1. Améliorer la fidélisation client

Le taux de réachat de 3.00 % est faible. Il serait pertinent de mettre en place des campagnes de fidélisation ciblées :

- offres personnalisées après un premier achat ;
- campagnes email de relance ;
- programme de fidélité ;
- recommandations de produits complémentaires ;
- promotions ciblées sur les catégories déjà achetées.

9.2. Renforcer les catégories performantes

Les catégories comme **health_beauty**, **watches_gifts** et **bed_bath_table** génèrent une part importante du chiffre d'affaires. L'entreprise pourrait renforcer ses actions commerciales sur ces catégories, notamment à travers des campagnes marketing, des promotions saisonnières et une meilleure mise en avant dans le catalogue.

9.3. Exploiter les régions à fort potentiel

La région **SP** génère le plus fort chiffre d'affaires. Elle représente donc une zone stratégique. Les régions **RJ** et **MG** sont également importantes. Il serait intéressant de comparer ces régions avec des zones ayant un panier moyen plus élevé mais un volume plus faible, afin d'identifier des opportunités de croissance.

9.4. Réduire les retards de livraison

Les régions avec des taux de retard élevés doivent faire l'objet d'une attention particulière. Une analyse complémentaire pourrait être menée par vendeur, par catégorie ou par transporteur afin d'identifier les causes des retards.

L'amélioration de la livraison peut avoir un impact direct sur la satisfaction client et donc sur le taux de réachat.

9.5. Identifier les produits premium

Certains produits génèrent un chiffre d'affaires important malgré un volume de ventes relativement faible. Ces produits premium peuvent être stratégiques, car ils contribuent fortement au revenu avec un panier moyen élevé.

10. Conclusion

Ce projet a permis de construire une analyse Business Intelligence complète à partir d'un dataset e-commerce réel. La démarche suivie couvre l'ensemble du cycle d'un projet Data Analyst : exploration, nettoyage, préparation, analyse SQL, création de KPIs, dashboard Power BI et recommandations business.

Les résultats montrent une activité commerciale importante, avec plus de **13.22 millions** de chiffre d'affaires sur les commandes livrées. Les catégories et régions les plus performantes ont été identifiées, ainsi que plusieurs axes d'amélioration liés à la fidélisation client et à la performance de livraison.

Le projet met en avant des compétences concrètes en Python, SQL, Power BI, DAX, analyse business et data storytelling. Il constitue une base solide pour démontrer une capacité à transformer des données brutes en informations exploitables pour la prise de décision.

English Version

11. Project Context

This project was developed to build a complete Business Intelligence analysis using real e-commerce data. The objective is to simulate a realistic business case where a company needs to better understand its sales performance, customers, products, regions, and delivery issues.

In an e-commerce environment, business decisions should not rely only on total revenue. A company needs to analyze several dimensions, including monthly sales trends, product category performance, regional performance, customer loyalty, and delivery quality.

This project follows a complete Data Analyst / BI Analyst workflow. Raw data was first explored, cleaned, and prepared using Python. SQL queries were then created to calculate the main business indicators. Finally, a Power BI dashboard was built to make the results clear, interactive, and easy to use.

The goal is not only to produce charts, but to transform raw data into a decision-making tool.

12. Business Objectives

The analysis aims to answer several key business questions:

- What is the revenue generated by delivered orders?
- How many orders were completed?
- What is the average order value?
- Which product categories generate the most revenue?
- Which regions perform best?
- Which products contribute the most to revenue?
- What is the level of customer loyalty?
- What is the repeat purchase rate?
- Which customers order most frequently?
- Which customers generate the highest revenue?
- What is the average delivery time?
- Which regions have the highest late delivery rates?

These questions cover three main business areas: sales performance, customer behavior, and logistics performance.

13. Dataset Overview

The dataset used is the **Brazilian E-Commerce Public Dataset by Olist**. It is a public dataset containing anonymized real-world data from a Brazilian marketplace.

The dataset covers several parts of the e-commerce process:

- orders;
- customers;
- products;
- product categories;
- payments;
- sellers;
- customer reviews;
- delivery dates;
- geographical information.

The dataset is composed of several CSV files connected through identifiers such as `order_id`, `customer_id`, `product_id`, and `seller_id`.

For the main analysis, the most important tables were:

- `olist_orders_dataset.csv`;
- `olist_order_items_dataset.csv`;
- `olist_customers_dataset.csv`;
- `olist_products_dataset.csv`;
- `olist_order_payments_dataset.csv`;
- `product_category_name_translation.csv`.

The final analysis focuses mainly on orders with the status `delivered`. This choice makes it possible to measure finalized sales and avoid including canceled, unavailable, or unfinished orders in the main KPIs.

14. Methodology

The methodology followed in this project is structured into four main steps.

14.1. Data Understanding and Exploration

The first step consisted of loading the CSV files into a Python notebook in order to inspect their structure, number of rows, available columns, data types, missing values, and duplicates.

This step is essential because it prevents building KPIs on misunderstood data. For example, one order can contain several products, which means that the order items table contains more rows than the orders table.

14.2. Data Cleaning and Preparation with Python

Date columns were converted to datetime format in order to support time-based analysis. Missing product categories were replaced with the value `unknown`, allowing the associated sales to be kept without losing revenue.

A central table called `sales_clean` was created by combining orders, order items, customers, products, categories, and payments.

A second table called `sales_delivered` was then created to keep only delivered orders. This table became the main source for SQL analysis and the Power BI dashboard.

14.3. SQL Analysis

A SQLite database was created to import the clean data. Several SQL queries were written to calculate KPIs and perform the main analyses:

- total revenue;
- number of orders;
- number of unique customers;
- average order value;
- monthly sales trend;
- sales by category;
- sales by region;
- top products;
- most loyal customers;

- repeat purchase rate;
- delivery times;
- late delivery rate by region.

This step helped validate the results before visualizing them in Power BI.

14.4. Power BI Dashboard

The Power BI dashboard was organized into several pages:

- **Executive Overview:** overview of the main KPIs;
- **Sales Analysis:** sales analysis by month, category, region, and product;
- **Delivery Analysis:** delivery time and late delivery analysis;
- **Customer Loyalty:** customer loyalty and high-value customer analysis.

DAX measures were created to dynamically calculate the indicators inside the dashboard.

15. Main KPIs

The main indicators calculated from delivered orders are:

KPI	Value
Total Revenue	13,221,498.11
Delivered Orders	96,478
Unique Customers	93,358
Items Sold	110,197
Average Order Value	137.04
Repeat Purchase Rate	3.00%
Average Delivery Time	12.01 days
Late Delivery Rate	7.91%

These KPIs provide a clear overview of the global e-commerce performance.

16. Sales Analysis

The sales analysis shows that the total revenue from delivered orders is approximately **13.22 million**. This amount represents product revenue, excluding shipping fees.

The monthly analysis helps observe how revenue evolves over time. It makes it possible to identify growth periods, weaker months, and potential seasonality trends.

The category analysis highlights the best-performing product categories. The **health_beauty** category generates the highest revenue. It is followed by categories such as **watches_gifts**, **bed_bath_table**, **sports_leisure**, and **computers_accessories**.

An interesting finding is that some categories may generate high revenue with a lower number of orders because they have a higher average order value. This is especially relevant for premium categories.

The regional analysis shows that the state of **SP** is by far the strongest in terms of sales volume and revenue. The regions **RJ** and **MG** are also among the most important areas.

17. Customer Analysis

The customer analysis shows that the dataset contains **93,358 unique customers** for **96,478 delivered orders**. The number of customers is therefore very close to the number of orders, which indicates that most customers purchased only once.

The repeat purchase rate is only **3.00%**. This result shows that customer retention is a major improvement opportunity. An e-commerce company with a low repeat purchase rate may depend heavily on acquiring new customers, which can increase marketing costs.

The analysis of top customers by number of orders identifies the most loyal customers. The analysis of top customers by revenue identifies high-value customers. These two dimensions are not always the same: a customer may order frequently but spend little, while another may order less frequently but generate higher total revenue.

This distinction is important for designing appropriate marketing actions.

18. Delivery Analysis

Delivery performance is an important part of the customer experience. In this project, the average delivery time is approximately **12.01 days**.

The late delivery rate is **7.91%**. This means that around 8 items out of 100 were delivered after the estimated delivery date.

The regional analysis shows that some regions have higher late delivery rates than the average, especially **AL**, **MA**, **SE**, **PI**, and **CE**. These regions would require deeper logistics analysis to identify potential causes such as distance, transportation network, sellers, order preparation, or delivery partners.

It is also important to distinguish between late delivery rate and average delivery time. A region can have a long average delivery time without a high late delivery rate if the estimated delivery dates are also long. On the other hand, a region can have a reasonable average delivery time but a high late delivery rate if the promised delivery times are too short.

19. Business Recommendations

Based on the results, several business recommendations can be proposed.

19.1. Improve Customer Retention

The repeat purchase rate of 3.00% is low. It would be relevant to implement targeted retention actions:

- personalized offers after a first purchase;
- email reactivation campaigns;
- loyalty program;
- product recommendations;
- targeted promotions based on previous purchases.

19.2. Strengthen High-Performing Categories

Categories such as **health_beauty**, **watches_gifts**, and **bed_bath_table** generate a significant share of revenue. The company could strengthen its commercial actions on these categories through marketing campaigns, seasonal promotions, and better catalog visibility.

19.3. Leverage High-Potential Regions

The **SP** region generates the highest revenue and is therefore a strategic area. The regions **RJ** and **MG** are also important. It would be useful to compare these regions with areas that have a higher average order value but lower volume, in order to identify growth opportunities.

19.4. Reduce Delivery Delays

Regions with high late delivery rates should be monitored carefully. A deeper analysis could be conducted by seller, category, or carrier to identify the causes of delays.

Improving delivery performance can directly impact customer satisfaction and, in the long term, repeat purchases.

19.5. Identify Premium Products

Some products generate high revenue despite relatively low sales volume. These premium products can be strategic because they strongly contribute to revenue with a high average price.

20. Conclusion

This project made it possible to build a complete Business Intelligence analysis using a real e-commerce dataset. The workflow covered the full cycle of a Data Analyst project: exploration, cleaning, preparation, SQL analysis, KPI creation, Power BI dashboarding, and business recommendations.

The results show significant commercial activity, with more than **13.22 million** in revenue from delivered orders. The best-performing categories and regions were identified, as well as several improvement opportunities related to customer retention and delivery performance.

This project demonstrates practical skills in Python, SQL, Power BI, DAX, business analysis, and data storytelling. It provides a strong example of how raw data can be transformed into actionable insights for decision-making.